Clasificación de lesiones mamarias en ecografía (BUSI)

Transfer learning y Grad-CAM

Validación externa y análisis de errores

Autor: Esp. Ing. Emmanuel Cardozo
Carrera: Maestría en Inteligencia Artificial, FIUBA.
Asignatura: Fundamentos de Medicina y aplicaciones de IA
Instancia: Propuesta inicial de proyecto.
Versión: 1.0 · 1 de octubre de 2026

Resumen

Se propone desarrollar y evaluar un prototipo de clasificación de lesiones mamarias en imágenes de ecografía, mediante una red convolucional preentrenada y ajuste fino. El conjunto BUSI se utilizará para el desarrollo y la evaluación interna; BUS-BRA se reservará para una evaluación externa retrospectiva. La tarea principal será distinguir lesiones benignas y malignas, considerando malignidad como clase positiva.

El aporte del proyecto estará en la calidad del diseño experimental: depuración documentada, prevención de fuga de información, evaluación de sensibilidad y especificidad, análisis de falsos negativos, calibración de las predicciones y exploración visual mediante Grad-CAM. Se investigará cuánto cambia el desempeño cuando el modelo se aplica a una fuente de datos distinta.

Se priorizará EfficientNet-B0 para mantener un alcance realizable. ResNet50 se considerará una comparación opcional. El resultado esperado será un experimento reproducible y una discusión crítica sobre sus límites, sin asumir que un buen desempeño retrospectivo habilita el uso clínico.

Pregunta que guía el proyecto

¿Qué capacidad de discriminación y qué patrones de error presenta un modelo de transfer learning entrenado con BUSI, y en qué medida se mantienen al evaluarlo en un conjunto externo sin reajustarlo?

Estado del trabajo: este documento presenta una idea y un protocolo propuesto. No se descargaron ni depuraron los datasets, no se entrenaron modelos y no se generaron resultados experimentales.

02 | Problema, justificación y objetivos

Problema y pertinencia para la materia

La clasificación de imágenes ecográficas permite estudiar un caso concreto de diagnóstico asistido por computadora (CAD): una imagen se transforma en una puntuación que debe interpretarse dentro de un contexto médico. Para este proyecto, la entrada será una imagen estática que ya contiene una lesión; no se abordará la búsqueda de lesiones en un examen completo ni el tamizaje de población asintomática.

Desde el punto de vista del diseño, interesa especialmente el falso negativo: una imagen etiquetada como maligna que el modelo clasifica como benigna. También se estudiarán los falsos positivos, porque aumentar la sensibilidad puede incrementar las alertas innecesarias. El proyecto no estimará demoras diagnósticas, biopsias evitadas ni beneficios asistenciales reales, ya que esos desenlaces requieren otro tipo de estudio.

Objetivo general

Implementar un clasificador binario de lesiones mamarias en ecografía y evaluar su discriminación, calibración, comportamiento externo y errores, mediante un protocolo reproducible que explicite las limitaciones de los datos.

Objetivos específicos

- Inventariar BUSI, separar imágenes de máscaras, identificar duplicados y documentar exclusiones antes de entrenar.
- Construir particiones independientes por paciente cuando exista una correspondencia verificable; en su ausencia, agrupar imágenes relacionadas y declarar la independencia no demostrada.
- Comparar un baseline sencillo con una red preentrenada y evaluar el efecto del ajuste fino.
- Medir sensibilidad, especificidad, AUC-ROC, precisión-recall y falsos negativos con umbrales elegidos únicamente en validación.
- Aplicar el modelo congelado a BUS-BRA y describir la variación de desempeño respecto de la prueba interna.
- Examinar Grad-CAM y casos de error para detectar posibles dependencias de textos, marcas o regiones ajenas a la lesión.

Hipótesis de trabajo y criterio de éxito

Se evaluará si el ajuste fino aporta mejoras frente a las características congeladas y si estas se sostienen en otro dataset. No se fija una accuracy objetivo ni se presupone superioridad. El éxito académico consistirá en responder la pregunta con evidencia trazable, incluso si el rendimiento externo resulta bajo.

03 | Datos propuestos y acceso

BUSI: desarrollo y prueba interna

La publicación de Al-Dhabyani y colaboradores describe 780 imágenes de 600 pacientes, distribuidas en 437 benignas, 210 malignas y 133 normales, con imágenes y máscaras en PNG [1]. Son cifras publicadas, previas a la auditoría que se realizará. La tarea binaria partirá de las 647 imágenes con lesión; los casos normales quedarán fuera del análisis principal. Las máscaras no constituyen imágenes adicionales de pacientes.

La descarga práctica puede realizarse desde la copia de BUSI en Kaggle [2]. Se conservarán la versión, fecha, condiciones de uso y huellas SHA-256 del archivo descargado y de las imágenes. La página de los autores está enlazada desde el artículo original, aunque su acceso puede fallar. La copia descargada deberá contrastarse con la descripción publicada.

BUS-BRA: evaluación externa prevista

BUS-BRA contiene 1.875 imágenes de 1.064 pacientes, adquiridas con cuatro equipos, e incluye información de patología, categorías BI-RADS y segmentaciones [4,5]. Se propone usarlo como fuente externa para la misma tarea benigno/maligno. Se verificará la vinculación entre imagen, paciente y etiqueta antes de definir la cohorte evaluable.

Se utilizará el campo de diagnóstico correspondiente, sin convertir automáticamente BI-RADS en una etiqueta de malignidad. BI-RADS y patología representan conceptos distintos. No se incorporarán las etiquetas, máscaras ni metadatos diagnósticos como entradas del clasificador.

Enlaces para comenzar

- **BUSI, descarga:** https://www.kaggle.com/datasets/aryashah2k/breast-ultrasound-images-dataset
- **BUSI, artículo original:** https://doi.org/10.1016/j.dib.2019.104863
- **BUSI, material para auditar duplicados:** https://data.mendeley.com/datasets/k8t3gnx9h6/1
- **BUS-BRA, descarga oficial:** https://zenodo.org/records/8231412
- **BUS-BRA, documentación de los autores:** https://github.com/wgomezf/BUS-BRA

Alcance de los formatos

Los conjuntos seleccionados se distribuyen en PNG [1,4]. No se describirá el experimento como entrenamiento con DICOM. La lectura y desidentificación de DICOM se planteará como extensión didáctica independiente, con archivos autorizados y sin convertir PNG a DICOM para simular datos clínicos originales.

04 | Depuración y prevención de fuga de información

Auditoría previa

La literatura ha señalado duplicados y otros problemas de BUSI; existe material suplementario para revisarlos [3]. Se construirá un manifiesto con identificador opaco, procedencia, SHA-256, dimensiones, clase de referencia, grupo de relación y motivo de exclusión. Los nombres originales con la clase se conservarán sólo en una correspondencia de auditoría; nunca se usarán como variables predictoras.

Se buscarán duplicados exactos mediante hashes y candidatos visualmente similares mediante hashes perceptuales. Los candidatos se revisarán manualmente: la semejanza no demuestra por sí sola identidad de paciente. También se controlarán coincidencias entre datasets. Ante una imagen repetida con etiquetas contradictorias, se consultará la fuente y, si no se resuelve, se excluirá del análisis principal sin inventar una etiqueta.

Textos, bordes, flechas y calibradores se revisarán por su potencial de actuar como atajos. Se preferirá recortar márgenes externos con una regla independiente de la clase. Si una marca invade la lesión, se registrará el caso; no se reconstruirá tejido con IA generativa. Las exclusiones por calidad se definirán antes de observar predicciones y se reportarán por clase.

Unidad de partición

La primera opción será separar por paciente con identificadores verificables. Si BUSI no permite reconstruir esa correspondencia, se usarán grupos de duplicados o imágenes relacionadas. El informe describirá entonces una evaluación por imagen agrupada, con riesgo residual de dependencia entre pacientes. Separar archivos aleatoriamente no basta para afirmar ausencia de fuga.

Se propone una división aproximada 60/20/20 para entrenamiento, validación y prueba interna, estratificada por clase y respetando grupos. Los tamaños finales dependerán de la depuración. Todas las imágenes, recortes y aumentos de un grupo permanecerán en una sola partición. El aumento de datos se aplicará después de dividir y únicamente al entrenamiento.

Reglas de congelamiento

La auditoría estructural se hará antes de particionar, sin resultados del modelo. Las decisiones aprendidas, los pesos de clase y cualquier ajuste de preprocesamiento se estimarán con entrenamiento; modelo, época y umbral se elegirán con validación. La prueba interna y BUS-BRA se abrirán para evaluación sólo después de congelar el protocolo. Se guardará un registro de decisiones y exclusiones.

05 | Implementación y herramientas

Entorno de trabajo

Se utilizará Python con PyTorch y torchvision para redes y entrenamiento; scikit-learn para baselines y métricas; pandas y NumPy para manifiestos y resultados; Pillow u OpenCV para lectura y saneamiento; Matplotlib para figuras; y una implementación de Grad-CAM compatible con PyTorch. Se fijarán versiones al iniciar el proyecto. La ejecución será posible mediante scripts, sin depender de una interfaz gráfica.

Una GPU local o un entorno académico con GPU facilitará los experimentos. Se registrarán dispositivo, memoria, tiempo y versiones. La disponibilidad de GPU deberá verificarse el primer día; los tiempos de entrenamiento no se prometerán antes de una prueba corta. Jupyter se usará, si resulta útil, para exploración y presentación, manteniendo el procedimiento reproducible en scripts.

Entrada y preprocesamiento

El modelo recibirá la imagen saneada, sin máscara de segmentación. Se conservará la proporción geométrica mediante redimensionamiento y relleno hasta 224 × 224 píxeles. La escala de grises se repetirá en tres canales para reutilizar pesos de ImageNet y se aplicará la normalización correspondiente a esos pesos.

El entrenamiento podrá incluir rotaciones pequeñas y reflexión horizontal, tras comprobar que no generan imágenes inadecuadas. Se evitarán deformaciones fuertes, inversiones verticales y filtros agresivos que alteren estructuras. No se incorporarán CLAHE ni eliminación de speckle al protocolo principal; cualquier variante deberá justificarse y seleccionarse sin mirar las pruebas.

Secuencia experimental acotada

- **Baseline 0:** predictor de clase mayoritaria y puntuación constante basada en la prevalencia de entrenamiento, para contextualizar las métricas.
- **Baseline 1:** características de EfficientNet-B0 congelada y regresión logística con regularización, ajustada sólo con los datos de desarrollo.
- **Modelo principal:** EfficientNet-B0 preentrenada, adaptación de la cabeza y posterior ajuste del último bloque. Se propone AdamW, hasta 20 épocas y detención temprana con paciencia de 4 épocas según AUC de validación.
- **Ampliación:** repetir el protocolo con ResNet50 sólo si el núcleo del proyecto está completo. No se realizará una búsqueda masiva de arquitecturas.

Se registrarán semillas, parámetros y cambios. Los pesos para compensar clases se calcularán únicamente con entrenamiento. La selección de época y del modelo principal seguirá una regla fijada antes de evaluar las pruebas; el empate se resolverá a favor del modelo más sencillo.

06 | Evaluación

Métricas y umbral

La clase positiva será malignidad. Se reportarán matriz de confusión con conteos absolutos, sensibilidad = VP/(VP+FN), especificidad = VN/(VN+FP), tasa de falsos negativos = FN/(VP+FN), valores predictivos positivo y negativo, F1, balanced accuracy y accuracy. Se acompañarán AUC-ROC y average precision (AP), indicando esta última como resumen de la curva precisión-recall, sin confundirla con otras integraciones de esa curva.

Se mostrarán dos puntos de operación: el umbral convencional 0,5 y un umbral elegido en validación para maximizar especificidad entre los que alcancen sensibilidad empírica de al menos 90%. El 90% será un objetivo exploratorio de ingeniería, no un estándar clínico. Si sólo se logra clasificando prácticamente todo como positivo, se mostrará ese costo. El umbral se conservará idéntico en ambas pruebas.

Incertidumbre y calibración

Se calcularán intervalos de confianza del 95% mediante bootstrap con 1.000 remuestreos de pacientes cuando haya identificadores, o de grupos de imágenes relacionadas cuando no los haya. Se declarará la unidad real; un intervalo por grupo no resuelve la falta de identidad de paciente. Se documentarán remuestreos sin ambas clases y denominadores nulos, sin asignarles valores ficticios.

Se examinarán Brier score y un diagrama de calibración con cinco intervalos de probabilidad, mostrando el número de observaciones por intervalo. La salida sigmoide se tratará como puntuación del modelo; sólo la evaluación permitirá valorar si aproxima frecuencias observadas. No se calibrará con el conjunto externo. Una recalibración futura requeriría datos de adaptación separados de una nueva prueba.

Generalización y costo de ejecución

Las métricas se presentarán por separado para BUSI y BUS-BRA, junto con la diferencia externa menos interna, sus tamaños y proporciones de clase. Los valores predictivos dependen de la composición de cada cohorte y no se extrapolarán directamente a un hospital. El análisis principal será por imagen; los intervalos respetarán agrupaciones disponibles y se explicará que varias imágenes pueden corresponder a una paciente.

También se informarán tiempo de entrenamiento, tamaño del modelo, memoria y latencia por imagen en el hardware utilizado. La latencia incluirá condiciones de medición, calentamiento, tamaño de lote y si contempla preprocesamiento. Estas mediciones describen factibilidad técnica, no impacto asistencial.

07 | Grad-CAM y análisis de errores

Explicación visual como herramienta de auditoría

Grad-CAM genera mapas de localización aproximada asociados a una clase a partir de gradientes en capas convolucionales [6]. Se utilizará la última capa convolucional del modelo, documentando la capa y la normalización del mapa. Se generará el mapa para malignidad en todos los casos revisados, incluso cuando la predicción sea benigna, para mantener un criterio consistente.

La visualización mostrará imagen saneada, mapa superpuesto, etiqueta de referencia, puntuación y clasificación al umbral congelado. No se presentará como una segmentación precisa, una explicación causal ni una confirmación de razonamiento médico correcto. Las verificaciones de sensibilidad de mapas al modelo ayudan a estudiar estos límites [7].

Selección de casos sin elegir sólo ejemplos favorables

Se construirá un registro de todos los falsos negativos y falsos positivos de ambas pruebas. Se revisarán visualmente todos los errores internos y una muestra externa reproducible de hasta 30 falsos negativos y 30 falsos positivos, si hubiera tantos. Se añadirán hasta 10 verdaderos positivos y 10 verdaderos negativos de cada fuente, elegidos con semilla fija. Se informarán los casos disponibles y los efectivamente revisados.

El registro distinguirá errores con puntuación extrema, casos próximos al umbral, imágenes de baja calidad, marcas residuales, varias lesiones y activaciones alejadas de la región anotada. Estas categorías serán descripciones técnicas; atribuir una causa clínica requerirá revisión de un especialista. Si no se dispone de ese apoyo, se declarará la ausencia de validación radiológica.

Uso limitado de las máscaras

Las máscaras originales se reservarán para auditoría posterior. Se podrá medir qué proporción de la activación positiva cae dentro de la lesión y si el máximo del mapa está en ella, informando también el área relativa de la máscara. Las transformaciones geométricas de imagen y máscara deberán ser consistentes. Una coincidencia alta no demostrará que la predicción sea correcta ni que el modelo sea seguro.

Como control exploratorio, se compararán mapas del modelo entrenado con mapas obtenidos tras aleatorizar la cabeza en una muestra fija. En imágenes con marcas externas se podrá medir el cambio de puntuación al ocultarlas mediante una regla predefinida. Estas pruebas buscarán dependencia de atajos; no se usarán para reajustar el modelo tras consultar el test. Cualquier mejora posterior se declarará como una nueva versión que necesita nueva evaluación.

08 | Relación con la materia, ética y limitaciones

Vinculación conceptual

La propuesta conecta procesamiento de imágenes, CAD, evaluación diagnóstica y responsabilidad en el uso de IA. A partir de los temas señalados por el autor, se relacionará con preprocesamiento y DICOM en Ruiz, y con validación y ética en Sorrentino. Las referencias exactas de esas clases deberán incorporarse cuando se disponga de sus materiales; no se atribuyen aquí afirmaciones textuales no verificadas.

El material de Rowensztein aportado para la materia pone el foco en protección de datos y responsabilidad humana. Las propuestas de cohortes previas orientan la estructura de este documento: problema, objetivos, diseño, evaluación, obstáculos y alcance. Sus ejemplos se usan como referencias de presentación, no como evidencia de desempeño del proyecto.

DICOM como extensión delimitada

Si se dispone de un estudio ecográfico DICOM autorizado, se podrá añadir una demostración de lectura con pydicom, inspección de modalidad y manejo de píxeles y metadatos. La desidentificación deberá contemplar encabezados y texto incrustado en píxeles; DICOM diferencia estas operaciones [9]. Cambiar nombres de archivo o borrar unas pocas etiquetas no garantiza anonimización. La extensión no se mezclará con las métricas de BUSI y no será necesaria para completar el núcleo del proyecto.

Marco ético

La Declaración de Helsinki orienta la protección de participantes, confidencialidad, integridad científica y evaluación ética de la investigación [8]. Antes de reutilizar datos se revisarán licencia, alcance de autorización y requisitos institucionales. El carácter público del dataset no se tomará como prueba automática de exención ética; cualquier determinación corresponderá a la institución competente.

Se conservarán originales sin sobrescribir, identificadores opacos y trazabilidad de modificaciones. No se intentará reidentificar pacientes ni se publicarán imágenes, modelos o datos sensibles en el repositorio. El uso de asistencia de IA para redacción o programación se declarará según las pautas de la materia, manteniendo responsabilidad del autor sobre contenido y resultados.

Límites que acompañarán los resultados

Se reconocerán tamaño acotado de BUSI, posible dependencia residual, selección de casos, diferencias de equipos, calidad variable de etiquetas y falta de variables demográficas completas. No se inferirá equidad entre subgrupos que los datos no permiten identificar. La validación externa retrospectiva ampliará la evidencia técnica, pero no equivaldrá a validación prospectiva ni a autorización para decisiones clínicas.

09 | Cronograma, entregables y decisiones pendientes

Semana 1: datos y diseño, días 1 a 5

Descarga y revisión de condiciones de uso; inventario; auditoría de máscaras, duplicados y etiquetas; inspección de calidad; definición de grupos y particiones. Se comprobarán acceso a BUS-BRA, correspondencia de sus etiquetas y disponibilidad de cómputo. Se implementarán baselines y una corrida corta. La primera devolución docente podrá concentrarse en la pregunta clínica, el alcance binario y las limitaciones de independencia.

Semana 2: entrenamiento y evaluación, días 6 a 10

Entrenamiento de EfficientNet-B0, selección con validación y congelamiento de modelo, preprocesamiento y umbral. Ejecución de la prueba interna y externa, cálculo de métricas e intervalos y generación de Grad-CAM. Se producirá una segunda presentación con el protocolo ejecutado, incidencias y primeros resultados reales, sin ocultar resultados desfavorables.

Semana 3: análisis y presentación, días 11 a 15

Revisión de errores, calibración y diferencias entre fuentes; controles de mapas; consolidación de resultados y limitaciones. Si sobra tiempo, comparación con ResNet50 bajo las mismas particiones. Preparación del informe experimental y defensa. En una versión de dos semanas se omitirán la segunda arquitectura, la extensión DICOM y la tarea de tres clases, preservando depuración y evaluación externa.

Entregables previstos

- Protocolo breve y manifiesto depurado con exclusiones justificadas, sin distribución de imágenes.
- Scripts reproducibles de preparación, entrenamiento, inferencia y evaluación; versiones y semillas registradas.
- Reporte por cohorte con métricas, intervalos, calibración, umbrales, tamaños y tiempos de cómputo.
- Galería de errores y Grad-CAM con selección reproducible y notas sobre posibles atajos.
- Ficha del modelo: propósito académico, población representada, entradas, límites, procedencia y uso no clínico.
- Presentación final que contraste la hipótesis con resultados realmente obtenidos para la defensa en la cátedra de Fundamentos de Medicina y Aplicaciones de IA.

Riesgos y criterio de cierre

Si BUSI no permite separar pacientes, esa limitación se mantendrá explícita; no se sustituirá por una afirmación de independencia. Si BUS-BRA no puede utilizarse, se documentará la causa y se acordará otra cohorte antes de entrenar; un split interno no se presentará como validación externa. Si no hubiera acceso externo en el plazo, la entrega se identificará como evaluación interna con validación externa pendiente.

Las decisiones a acordar con la cátedra son el alcance binario, la aceptación de una evaluación por grupos cuando falten identificadores, la disponibilidad de revisión clínica y el carácter opcional de DICOM. El trabajo se considerará completo cuando el procedimiento sea reproducible y sus conclusiones estén delimitadas por la evidencia, sin exigir alcanzar un valor arbitrario de accuracy.

10 | Bibliografía y materiales de referencia

Datos y metodología

[1] Al-Dhabyani W, Gomaa M, Khaled H, Fahmy A. Dataset of breast ultrasound images. Data in Brief. 2020;28:104863. https://doi.org/10.1016/j.dib.2019.104863

[2] Breast Ultrasound Images Dataset. Copia de BUSI en Kaggle, publicada por Aryashah2k. Recurso de descarga; citar también el artículo original. https://www.kaggle.com/datasets/aryashah2k/breast-ultrasound-images-dataset

[3] Pawlowska A, Karwat P, Zolek N. Supplementary files DIB-D-23-00350. Mendeley Data, v1, 2023. Material de la carta al editor sobre duplicados y otros problemas de BUSI. https://doi.org/10.17632/k8t3gnx9h6.1

[4] Gómez-Flores W, Gregorio-Calas MJ, Pereira WCA. BUS-BRA: A breast ultrasound dataset for assessing computer-aided diagnosis systems. Medical Physics. 2024;51:3110-3123. https://doi.org/10.1002/mp.16812

[5] Gómez-Flores W y colaboradores. BUS-BRA, conjunto de datos en Zenodo. https://zenodo.org/records/8231412

[6] Selvaraju RR y colaboradores. Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. ICCV, 2017. https://arxiv.org/abs/1610.02391

[7] Adebayo J y colaboradores. Sanity Checks for Saliency Maps. NeurIPS, 2018. https://arxiv.org/abs/1810.03292

[8] World Medical Association. Declaration of Helsinki: Ethical Principles for Medical Research Involving Human Participants. Revisión de 2024. https://www.wma.net/policies-post/wma-declaration-of-helsinki/

[9] DICOM. PS3.15, Basic Application Level Confidentiality Options, E.3.1: Clean Pixel Data Option. Edición consultada 2022e. https://dicom.nema.org/medical/dicom/2022e/output/chtml/part15/sect_E.3.html

Materiales aportados para orientar la propuesta

Di Lanzo, Liliana. Presentación sobre evaluación preoperatoria de estrés y fatiga en cirujanos, 10 diapositivas; y propuesta escrita sobre el mismo tema, 6 páginas, sin autoría explícita verificada en el texto extraído. Corti, Gastón. Sistema inteligente para detección automática de sepsis en pacientes internados, versión revisada, 9 páginas. Rowensztein, Hernán. Potenciando la práctica clínica con inteligencia artificial, FIUBA. Materiales docentes aportados por el autor; sin fecha editorial verificada.

Nota de alcance bibliográfico: enlaces y fuentes web consultados el 2 de octubre de 2026. Las cifras de los datasets son las reportadas por sus fuentes; los conteos definitivos, licencias de la copia descargada y correspondencias de pacientes deberán verificarse durante la implementación.